

Modelado de Datos Analíticos — Recursos Humanos

Ejercicios Prácticos: STAR Schema, Snowflake Schema y Comparación

Integrantes:

- Diego Alejandro Escobar Barahona
- Daniella Marissa Navarro Araniva

Repositorio de GitHub: https://github.com/bapatata688/modelado_analitico

Ejercicio 1 — STAR Schema para Recursos Humanos

Enunciado

Construir un STAR Schema para un sistema de Recursos Humanos.

Requerimientos:

- Crear: fact salarios, dim empleados, dim departamentos, dim tiempo, dim sedes
- Generar mínimo 1000 registros
- Analizar: salarios por departamento, salarios por sede, promedio salarial, top empleados
- Mostrar KPIs empresariales utilizando Python

```
In [118... import pandas as pd
import random
from faker import Faker

fake = Faker('es_Es')
random.seed(42)
```

```
In [119... # Dimension departamentos

lista_departamentos = [
    "Tecnologia",
    "Ventas",
    "Finanzas",
    "RRHH"
]

departamentos = []

for i, dep in enumerate(lista_departamentos, start=1):
```

```

departamentos.append({
    "departamento_key": i,
    "departamento": dep,
    "gerente": fake.name(),
    "tipo_departamento": random.choice([
        "Operativo",
        "Administrativo",
        "Estrategico"
    ])
})

dim_departamentos = pd.DataFrame(departamentos)

print(dim_departamentos)

```

	departamento_key	departamento	gerente \
0	1	Tecnologia	Amanda Bautista-Tovar
1	2	Ventas	Julián Manrique Solera
2	3	Finanzas	Marisa Castrillo
3	4	RRHH	Fabricio Juanito Gomila Agudo

	tipo_departamento
0	Estrategico
1	Operativo
2	Operativo
3	Estrategico

In [120...

```

# Dimension Sedes

lista_sedes = [
    ("Sede Central", "San Salvador"),
    ("Sede Occidental", "Santa Ana"),
    ("Sede Oriental", "San Miguel")
]

sedes = []

for i, (nombre, ciudad) in enumerate(lista_sedes, start=1):

    sedes.append({
        "sede_key": i,
        "sede": nombre,
        "ciudad": ciudad,
    })

dim_sedes = pd.DataFrame(sedes)

print(dim_sedes)

```

	sede_key	sede	ciudad
0	1	Sede Central	San Salvador
1	2	Sede Occidental	Santa Ana
2	3	Sede Oriental	San Miguel

In [121...

```

# Dimension de empleados

empleados = []

```

```

for i in range(1, 101):

    empleados.append({
        "empleado_key": i,
        "nombre_empleado": fake.name(),
        "puesto": random.choice([
            "Analista",
            "Coordinador",
            "Supervisor",
            "Gerente",
        ]),
        "nivel": random.choice([
            "Junior",
            "Senior"
        ]),
        "departamento_key": random.randint(1, 5),
        "sede_key": random.randint(1, 5)
    })

dim_empleados = pd.DataFrame(empleados)

print(dim_empleados.head())

```

	empleado_key	nombre_empleado	puesto	nivel	\
0	1	Reyna Heredia-Checa	Supervisor	Junior	
1	2	Florina Escobar Rincón	Analista	Junior	
2	3	Ximena Coll Ávila	Analista	Junior	
3	4	Haroldo Echevarría Ribera	Coordinador	Junior	
4	5	Albano Noguera Gual	Gerente	Junior	

	departamento_key	sede_key
0	2	2
1	5	4
2	1	2
3	5	2
4	4	5

In [122...

```

# Dimension tiempo

meses = [
    "Enero", "Febrero", "Marzo",
    "Abril", "Mayo", "Junio",
    "Julio", "Agosto", "Septiembre",
    "Octubre", "Noviembre", "Diciembre"
]

tiempo = []

for i, mes in enumerate(meses, start=1):

    tiempo.append({
        "fecha_key": i,
        "mes": mes,
        "año": 2026
    })

```

```
dim_tiempo = pd.DataFrame(tiempo)

print(dim_tiempo)
```

	fecha_key	mes	año
0	1	Enero	2026
1	2	Febrero	2026
2	3	Marzo	2026
3	4	Abril	2026
4	5	Mayo	2026
5	6	Junio	2026
6	7	Julio	2026
7	8	Agosto	2026
8	9	Septiembre	2026
9	10	Octubre	2026
10	11	Noviembre	2026
11	12	Diciembre	2026

In [123... *# Tabla Fact con Los salarios*

```
salarios = []

for i in range(1, 1001):

    salario_base = round(random.uniform(400.00, 3000.00), 2)

    bonificacion = round(random.uniform(0.00, 500.00), 2)

    total = round(salario_base + bonificacion, 2)

    salarios.append({
        "salario_id": i,
        "empleado_key": random.randint(1, 100),
        "fecha_key": random.randint(1, 12),
        "salario_base_usd": salario_base,
        "bonificacion_usd": bonificacion,
        "total_usd": total
    })

fact_salarios = pd.DataFrame(salarios)

print(fact_salarios.head())
print(f"\nTotal de registros: {len(fact_salarios)}")
```

	salario_id	empleado_key	fecha_key	salario_base_usd	bonificacion_usd	\
0	1	56	10	1298.79	393.21	
1	2	74	4	2959.01	57.82	
2	3	1	9	1062.28	354.39	
3	4	93	12	2806.50	269.23	
4	5	56	2	2316.30	98.52	

	total_usd
0	1692.00
1	3016.83
2	1416.67
3	3075.73
4	2414.82

Total de registros: 1000

In [124... *# Union para hacer el esquema star*

```

modelo_star = fact_salarios.merge(
    dim_empleados,
    on="empleado_key"
).merge(
    dim_departamentos,
    on="departamento_key"
).merge(
    dim_sedes,
    on="sede_key"
).merge(
    dim_tiempo,
    on="fecha_key"
)

print(modelo_star.head())

```

	salario_id	empleado_key	fecha_key	salario_base_usd	bonificacion_usd	\
0	2	74	4	2959.01	57.82	
1	3	1	9	1062.28	354.39	
2	4	93	12	2806.50	269.23	
3	6	80	6	2867.07	460.39	
4	8	52	12	1204.14	204.20	

	total_usd	nombre_empleado	puesto	nivel	\
0	3016.83	Hermenegildo Carlos Batalla Sabater	Supervisor	Junior	
1	1416.67	Reyna Heredia-Checa	Supervisor	Junior	
2	3075.73	Manu Carballo Pina	Coordinador	Junior	
3	3327.46	Roldán Santiago Tudela Lozano	Coordinador	Senior	
4	1408.34	Macarena Salamanca Pacheco	Gerente	Junior	

	departamento_key	sede_key	departamento	gerente	\
0	3	1	Finanzas	Marisa Castrillo	
1	2	2	Ventas	Julián Manrique Solera	
2	4	1	RRHH	Fabricio Juanito Gomila Agudo	
3	2	3	Ventas	Julián Manrique Solera	
4	1	1	Tecnologia	Amanda Bautista-Tovar	

	tipo_departamento	sede	ciudad	mes	año
0	Operativo	Sede Central	San Salvador	Abril	2026
1	Operativo	Sede Occidental	Santa Ana	Septiembre	2026
2	Estrategico	Sede Central	San Salvador	Diciembre	2026
3	Operativo	Sede Oriental	San Miguel	Junio	2026
4	Estrategico	Sede Central	San Salvador	Diciembre	2026

In [125...

```
# -----
# KPI 1 – Salarios por departamento

salarios_departamento = modelo_star.groupby(
    "departamento"
)[["total_usd"]].sum().sort_values(ascending=False)

print(salarios_departamento)
```

```
departamento
Tecnologia    350481.64
Ventas        291958.27
RRHH          177443.31
Finanzas      158401.20
Name: total_usd, dtype: float64
```

In [126...

```
# -----
# KPI 2 – Salarios por sede

salarios_sede = modelo_star.groupby(
    "sede"
)[["total_usd"]].sum().sort_values(ascending=False)

print(salarios_sede)
```

```
sede
Sede Occidental    380340.83
Sede Central      325860.24
Sede Oriental     272083.35
Name: total_usd, dtype: float64
```

```
In [127... # -----
# KPI 3 – salario promedio por departamento

promedio_departamento = modelo_star.groupby(
    "departamento"
)["total_usd"].mean().round(2)

print(promedio_departamento)
```

```
departamento
Finanzas    1931.72
RRHH        1949.93
Tecnologia  1904.79
Ventas      2085.42
Name: total_usd, dtype: float64
```

```
In [128... # -----
# KPI 4 – Salarios al mes

salarios_mes = modelo_star.groupby(
    "mes"
)["total_usd"].sum().sort_values(ascending=False)

print(salarios_mes)
```

```
mes
Octubre    99134.16
Diciembre  97941.45
Noviembre  92495.33
Junio      88235.05
Enero      85792.49
Agosto    84463.62
Septiembre 82574.49
Abril      82241.73
Febrero    80370.49
Mayo       68037.89
Marzo      64634.17
Julio      52363.55
Name: total_usd, dtype: float64
```

```
In [129... # -----
# KPI 5 – Top 10 empleados con mayor salario

top_empleados = modelo_star.groupby(
    "nombre_empleado"
)["total_usd"].sum().sort_values(
    ascending=False
).head(10)

print(top_empleados)
```

nombre_empleado	
Adelardo Sedano Calderon	34898.67
Manu Carballo Pina	30400.96
Cristian Blas Leon Almansa	28808.20
Valeria Hervia Balaguer	28344.26
Julio Galan	27933.57
Américo Nogués Linares	27583.51
Aníbal Noé Barrio Isern	27192.85
Felicidad Nicolás Gomis	26649.53
Irene Barco Peiró	25997.56
Alejandra María Manuela Torrens Álamo	25963.39

Name: total_usd, dtype: float64

Conclusión — Ejercicio 1 (STAR Schema)

Se construyó exitosamente un STAR Schema para el área de Recursos Humanos con 1000 registros en la tabla fact, aplicado al contexto empresarial de El Salvador con salarios expresados en dólares (USD).

El modelo centraliza la tabla `fact_salarios` con métricas clave (`salario_base_usd` , `bonificacion_usd` , `descuento_usd` , `total_usd`) rodeada de cuatro dimensiones desnormalizadas: empleados, departamentos, sedes y tiempo.

Esta estructura permitió calcular KPIs como salarios por departamento, por sede, promedios salariales y el ranking de empleados con mayor compensación total, todo mediante operaciones simples de `groupby` sin JOINS complejos.

Ejercicio 2 — Snowflake Schema para Recursos Humanos

Enunciado

Construir un Snowflake Schema para un sistema de Recursos Humanos.

Requerimientos:

- Crear: fact salarios, dim empleados, dim departamentos, dim puestos, dim sedes, dim regiones, dim tiempo
- Normalizar: departamentos, puestos, regiones
- Generar mínimo 1500 registros
- Analizar: salarios por región, salarios por puesto, salarios por departamento, promedio salarial
- Mostrar Top 10 empleados con mayor salario

In [130...

```
import pandas as pd
import random
```



```
from faker import Faker
```

```
fake = Faker('es_Es')
```

```
random.seed(99)
```

In [131... *# Dimension regiones normalizada 1*

```
lista_regiones = [
    "Zona Central",
    "Zona Occidental",
    "Zona Oriental",
]

regiones = []

for i, region in enumerate(lista_regiones, start=1):

    regiones.append({
        "region_key": i,
        "region": region,
    })

dim_regiones = pd.DataFrame(regiones)

print(dim_regiones)
```

	region_key	region
0	1	Zona Central
1	2	Zona Occidental
2	3	Zona Oriental

In [132... *# Dimension de sedes normalizada 2 dependiendo de cual sea la region*

```
lista_sedes_snow = [
    ("Sede San Salvador", 1),
    ("Sede Santa Ana", 2),
    ("Sede San Miguel", 3),
]

sedes_snow = []

for i, (nombre, region_key) in enumerate(
    lista_sedes_snow, start=1
):

    sedes_snow.append({
        "sede_key": i,
        "sede": nombre,
        "region_key": region_key
    })

dim_sedes_snow = pd.DataFrame(sedes_snow)

print(dim_sedes_snow)
```

	sede_key	sede	region_key
0	1	Sede San Salvador	1
1	2	Sede Santa Ana	2
2	3	Sede San Miguel	3

```
In [133... # Dimension de puestos normalizada

lista_puestos = [
    ("Analista", "Junior"),
    ("Coordinador", "Senior"),
    ("Supervisor", "Senior"),
    ("Gerente", "Senior"),
]

puestos = []

for i, (puesto, nivel) in enumerate(
    lista_puestos, start=1
):

    puestos.append({
        "puesto_key": i,
        "puesto": puesto,
        "nivel": nivel
    })

dim_puestos = pd.DataFrame(puestos)

print(dim_puestos)
```

	puesto_key	puesto	nivel
0	1	Analista	Junior
1	2	Coordinador	Senior
2	3	Supervisor	Senior
3	4	Gerente	Senior

```
In [134... # Dimension de departamentos normalizada

lista_depa_snow = [
    ("Tecnologia", "Estrategico"),
    ("Ventas", "Operativo"),
    ("Finanzas", "Administrativo"),
    ("RRHH", "Administrativo"),
]

departamentos_snow = []

for i, (dep, tipo) in enumerate(
    lista_depa_snow, start=1
):

    departamentos_snow.append({
        "departamento_key": i,
        "departamento": dep,
        "tipo_departamento": tipo
    })
```

```
dim_departamentos_snow = pd.DataFrame(departamentos_snow)

print(dim_departamentos_snow)
```

	departamento_key	departamento	tipo_departamento
0	1	Tecnologia	Estrategico
1	2	Ventas	Operativo
2	3	Finanzas	Administrativo
3	4	RRHH	Administrativo

In [135... *# Dimension de empleados*

```
empleados_snow = []

for i in range(1, 126):

    empleados_snow.append({
        "empleado_key": i,
        "nombre_empleado": fake.name(),
        "puesto_key": random.randint(1, 4),
        "departamento_key": random.randint(1, 4),
        "sede_key": random.randint(1, 3)
    })

dim_empleados_snow = pd.DataFrame(empleados_snow)

print(dim_empleados_snow.head())
```

	empleado_key	nombre_empleado	puesto_key	departamento_key	\
0	1	Julio Asensio Cardona	4	4	
1	2	Herberto Doménech Trillo	2	2	
2	3	Rosalía Ruiz Vicens	2	1	
3	4	Moisés Sanjuan	4	1	
4	5	Jordana Torre	4	2	

	sede_key
0	1
1	1
2	2
3	3
4	2

In [136... *# Dimension de tiempo*

```
meses = [
    "Enero", "Febrero", "Marzo",
    "Abril", "Mayo", "Junio",
    "Julio", "Agosto", "Septiembre",
    "Octubre", "Noviembre", "Diciembre"
]

tiempo_snow = []

for i, mes in enumerate(meses, start=1):

    tiempo_snow.append({
```

```

        "fecha_key": i,
        "mes": mes,
        "año": 2026
    })

dim_tiempo_snow = pd.DataFrame(tiempo_snow)

print(dim_tiempo_snow)

```

	fecha_key	mes	año
0	1	Enero	2026
1	2	Febrero	2026
2	3	Marzo	2026
3	4	Abril	2026
4	5	Mayo	2026
5	6	Junio	2026
6	7	Julio	2026
7	8	Agosto	2026
8	9	Septiembre	2026
9	10	Octubre	2026
10	11	Noviembre	2026
11	12	Diciembre	2026

In [137...

```

# Tabla Fact de salarios

salarios_snow = []

for i in range(1, 1501):

    salario_base = round(random.uniform(400.00, 3000.00), 2)

    bonificacion = round(random.uniform(0.00, 600.00), 2)

    total = round(salario_base + bonificacion, 2)

    salarios_snow.append({
        "salario_id": i,
        "empleado_key": random.randint(1, 125),
        "fecha_key": random.randint(1, 12),
        "salario_base_usd": salario_base,
        "bonificacion_usd": bonificacion,
        "total_usd": total
    })

fact_salarios_snow = pd.DataFrame(salarios_snow)

print(fact_salarios_snow.head())
print(f"\nTotal de registros: {len(fact_salarios_snow)}")

```

	salario_id	empleado_key	fecha_key	salario_base_usd	bonificacion_usd	\
0	1	63	4	815.68	440.18	
1	2	79	4	2260.22	60.27	
2	3	61	12	2756.19	104.15	
3	4	88	5	2733.27	103.43	
4	5	103	9	836.39	309.50	

	total_usd
0	1255.86
1	2320.49
2	2860.34
3	2836.70
4	1145.89

Total de registros: 1500

In [138...

```
# Esquema del snowflake

modelo_snow = fact_salarios_snow.merge(
    dim_empleados_snow,
    on="empleado_key"
).merge(
    dim_puestos,
    on="puesto_key"
).merge(
    dim_departamentos_snow,
    on="departamento_key"
).merge(
    dim_sedes_snow,
    on="sede_key"
).merge(
    dim_regiones,
    on="region_key"
).merge(
    dim_tiempo_snow,
    on="fecha_key"
)

print(modelo_snow.head())
```

	salario_id	empleado_key	fecha_key	salario_base_usd	bonificacion_usd	\
0	1	63	4	815.68	440.18	
1	2	79	4	2260.22	60.27	
2	3	61	12	2756.19	104.15	
3	4	88	5	2733.27	103.43	
4	5	103	9	836.39	309.50	

	total_usd	nombre_empleado	puesto_key	departamento_key	sede_key	\
0	1255.86	Josefa Leiva Ávila	1	1	1	
1	2320.49	Haydée del Lerma	3	2	1	
2	2860.34	Valentín Garcés Losada	3	2	3	
3	2836.70	Filomena Ayala Agustí	2	2	3	
4	1145.89	Noelia Huerta Alsina	3	2	1	

	puesto	nivel	departamento	tipo_departamento	sede	\
0	Analista	Junior	Tecnologia	Estrategico	Sede San Salvador	
1	Supervisor	Senior	Ventas	Operativo	Sede San Salvador	
2	Supervisor	Senior	Ventas	Operativo	Sede San Miguel	
3	Coordinador	Senior	Ventas	Operativo	Sede San Miguel	
4	Supervisor	Senior	Ventas	Operativo	Sede San Salvador	

	region_key	region	mes	año
0	1	Zona Central	Abril	2026
1	1	Zona Central	Abril	2026
2	3	Zona Oriental	Diciembre	2026
3	3	Zona Oriental	Mayo	2026
4	1	Zona Central	Septiembre	2026

In [139...

```
# -----
# KPI 1 – Salarios por region

salarios_region = modelo_snow.groupby(
    "region"
)[["total_usd"]].sum().sort_values(ascending=False)

print(salarios_region)
```

```
region
Zona Central      1174422.49
Zona Occidental    946064.94
Zona Oriental      907178.09
Name: total_usd, dtype: float64
```

In [140...

```
# -----
# KPI 2 – Salarios por puestos

salarios_puesto = modelo_snow.groupby(
    "puesto"
)[["total_usd"]].sum().sort_values(ascending=False)

print(salarios_puesto)
```

```
puesto
Gerente      908408.30
Supervisor   819853.47
Coordinador  690014.02
Analista     609389.73
Name: total_usd, dtype: float64
```

```
In [141... # -----
# KPI 3 – Salarios por departamento

salarios_dep_snow = modelo_snow.groupby(
    "departamento"
)["total_usd"].sum().sort_values(ascending=False)

print(salarios_dep_snow)
```

```
departamento
Ventas      899444.92
Tecnologia  777538.87
Finanzas    683201.85
RRHH        667479.88
Name: total_usd, dtype: float64
```

```
In [142... # -----
# KPI 4 – Salario promedio general

promedio_general = round(modelo_snow["total_usd"].mean(), 2)

print(f"Promedio Salarial General: ${promedio_general} USD")
```

Promedio Salarial General: \$2018.44 USD

```
In [143... # -----
# KPI 5 – Top 10 empleados con mayor salario

top_empleados_snow = modelo_snow.groupby(
    "nombre_empleado"
)["total_usd"].sum().sort_values(
    ascending=False
).head(10)

print(top_empleados_snow)
```

```
nombre_empleado
Haydée del Lerma      43484.05
Rosalía Ruiz Vicens   41729.88
Micaela Doménech Manuel 40227.43
Rogelio Carrasco-Quesada 39796.55
Abel Clavero Alba     39748.26
Isidoro Escobar Carretero 38855.20
Calisto Merino Fabra   36884.08
Josefa Leiva Ávila     36299.07
Pili Guardiola Antón   35778.80
Sigfrido Gaya Juárez   35436.28
Name: total_usd, dtype: float64
```

Conclusión — Ejercicio 2 (Snowflake Schema)

Se construyó un Snowflake Schema con 1500 registros normalizando las dimensiones de puestos, departamentos y la jerarquía sedes

Al separar la información en tablas más pequeñas y relacionadas se redujo la redundancia: la región ya no se repite en cada empleado sino que se hereda a través de la sede. Esto requiere más JOINS encadenados durante la construcción del modelo, pero garantiza mayor integridad y menor uso de almacenamiento.

Los KPIs calculados muestran la distribución salarial a nivel de región, puesto y departamento, ofreciendo una visión jerárquica del gasto en nómina propia del Snowflake Schema.

Ejercicio 3 — STAR vs Snowflake Schema para Recursos Humanos

Enunciado

Construir dos modelos analíticos para Recursos Humanos: STAR Schema y Snowflake Schema, utilizando el mismo dataset.

Requerimientos:

- Generar mínimo 5000 registros
- Construir dimensiones y fact table para ambos modelos
- Realizar KPIs, agrupaciones y análisis comparativos
- Medir tiempo de ejecución y complejidad de consultas
- Analizar ventajas y desventajas de cada modelo

In [144...

```
import pandas as pd
import random
import time
from faker import Faker

fake = Faker('es_Es')
random.seed(77)
```

In [145...

```
# Datos compartidos

lista_dep = ["Tecnologia", "Ventas", "Finanzas", "RRHH"]
lista_pues = ["Analista", "Coordinador", "Supervisor", "Gerente"]
lista_sedes = ["San Salvador", "Santa Ana", "San Miguel"]
lista_reg = ["Zona Central", "Zona Occidental", "Zona Oriental"]

meses = [
    "Enero", "Febrero", "Marzo", "Abril",
    "Mayo", "Junio", "Julio", "Agosto",
```



```

    "Septiembre", "Octubre", "Noviembre", "Diciembre"
]

print("Datos base definidos")

```

Datos base definidos

```

In [146... # Dimension star desnormalizada

emp_star = []

for i in range(1, 201):

    dep = random.choice(lista_dep)
    pues = random.choice(lista_pues)
    sede = random.choice(lista_sedes)
    reg = lista_reg[lista_sedes.index(sede)]

    emp_star.append({
        "empleado_key": i,
        "nombre_empleado": fake.name(),
        "puesto": pues,
        "departamento": dep,
        "tipo_departamento": random.choice([
            "Operativo",
            "Administrativo",
            "Estrategico"
        ]),
        "sede": sede,
        "region": reg,
    })

dim_emp_star = pd.DataFrame(emp_star)

dim_tiempo_cmp = pd.DataFrame([
    {
        "fecha_key": i,
        "mes": mes,
        "trimestre": f"Q{((i-1)//3)+1}",
        "año": 2025
    }
    for i, mes in enumerate(meses, start=1)
])

print("Dimensiones STAR creadas")
print(dim_emp_star.head())

```

Dimensiones STAR creadas

	empleado_key	nombre_empleado	puesto	departamento	\
0	1	Fabio Rozas Alba	Supervisor	Finanzas	
1	2	Macario Jaime Serra	Analista	Ventas	
2	3	Ricardo del Amaya	Coordinador	Ventas	
3	4	Reyna Serrano Chaparro	Supervisor	Tecnologia	
4	5	Mar Morán Nieto	Coordinador	Ventas	

	tipo_departamento	sede	region
0	Operativo	San Salvador	Zona Central
1	Administrativo	Santa Ana	Zona Occidental
2	Estrategico	San Miguel	Zona Oriental
3	Administrativo	San Salvador	Zona Central
4	Administrativo	San Miguel	Zona Oriental

In [147...

```
# Dimension snowflake normalizada

dim_reg_cmp = pd.DataFrame([
    {"region_key": i+1, "region": r}
    for i, r in enumerate(lista_reg)
])

dim_sed_cmp = pd.DataFrame([
    {"sede_key": i+1, "sede": s, "region_key": i+1}
    for i, s in enumerate(lista_sedes)
])

dim_dep_cmp = pd.DataFrame([
    {
        "departamento_key": i+1,
        "departamento": d,
        "tipo_departamento": random.choice([
            "Operativo",
            "Administrativo",
            "Estrategico"
        ])
    }
    for i, d in enumerate(lista_dep)
])

dim_pues_cmp = pd.DataFrame([
    {"puesto_key": i+1, "puesto": p}
    for i, p in enumerate(lista_pues)
])

emp_snow = []

for i in range(1, 201):

    emp_snow.append({
        "empleado_key": i,
        "nombre_empleado": dim_emp_star.loc[
            dim_emp_star["empleado_key"] == i,
            "nombre_empleado"
        ].values[0],
        "puesto_key": random.randint(1, 4),
```

```

        "departamento_key": random.randint(1, 4),
        "sede_key": random.randint(1, 3)
    })

dim_emp_snow = pd.DataFrame(emp_snow)

print("Dimensiones Snowflake creadas")
print(dim_emp_snow.head())

```

Dimensiones Snowflake creadas

	empleado_key	nombre_empleado	puesto_key	departamento_key	\
0	1	Fabio Rozas Alba	1	1	
1	2	Macario Jaume Serra	2	3	
2	3	Ricardo del Amaya	1	4	
3	4	Reyna Serrano Chaparro	4	3	
4	5	Mar Morán Nieto	2	1	

	sede_key
0	1
1	1
2	1
3	3
4	2

In [148... *# Tabla fact compartida con los registros*

```

salarios_cmp = []

for i in range(1, 5001):

    salario_base = round(random.uniform(400.00, 3000.00), 2)

    bonificacion = round(random.uniform(0.00, 700.00), 2)

    total = round(salario_base + bonificacion, 2)

    salarios_cmp.append({
        "salario_id": i,
        "empleado_key": random.randint(1, 200),
        "fecha_key": random.randint(1, 12),
        "salario_base_usd": salario_base,
        "bonificacion_usd": bonificacion,
        "total_usd": total
    })

fact_cmp = pd.DataFrame(salarios_cmp)

print(fact_cmp.head())
print(f"\nTotal de registros: {len(fact_cmp)}")

```

	salario_id	empleado_key	fecha_key	salario_base_usd	bonificacion_usd \
0	1	76	10	2271.90	673.47
1	2	28	9	1849.37	326.81
2	3	126	12	1554.61	72.33
3	4	101	12	2413.31	68.70
4	5	27	11	1147.75	405.45

	total_usd
0	2945.37
1	2176.18
2	1626.94
3	2482.01
4	1553.20

Total de registros: 5000

In [149...

```
# Prueba del esquema star

inicio_star = time.time()

modelo_star_cmp = fact_cmp.merge(
    dim_emp_star,
    on="empleado_key"
).merge(
    dim_tiempo_cmp,
    on="fecha_key"
)

kpi_star = modelo_star_cmp.groupby(
    "departamento"
)["total_usd"].sum()

fin_star = time.time()
tiempo_star = round(fin_star - inicio_star, 6)

print("Resultado STAR Schema")
print(kpi_star)
print(f"\nTiempo STAR: {tiempo_star} segundos")
```

Resultado STAR Schema

departamento	
Finanzas	2250102.73
RRHH	3236279.92
Tecnologia	2928035.30
Ventas	1769448.51

Name: total_usd, dtype: float64

Tiempo STAR: 0.006742 segundos

In [150...

```
# prueba del esquema snowflake

inicio_snow = time.time()

modelo_snow_cmp = fact_cmp.merge(
    dim_emp_snow,
    on="empleado_key"
```

```

).merge(
    dim_pues_cmp,
    on="puesto_key"
).merge(
    dim_dep_cmp,
    on="departamento_key"
).merge(
    dim_sed_cmp,
    on="sede_key"
).merge(
    dim_reg_cmp,
    on="region_key"
).merge(
    dim_tiempo_cmp,
    on="fecha_key"
)

kpi_snow = modelo_snow_cmp.groupby(
    "departamento"
)["total_usd"].sum()

fin_snow = time.time()
tiempo_snow = round(fin_snow - inicio_snow, 6)

print("Resultado Snowflake Schema")
print(kpi_snow)
print(f"\nTiempo Snowflake: {tiempo_snow} segundos")

```

Resultado Snowflake Schema

departamento

Finanzas 2711830.78

RRHH 2842665.39

Tecnologia 2523793.43

Ventas 2105576.86

Name: total_usd, dtype: float64

Tiempo Snowflake: 0.009951 segundos

In [151...

```

# KPI de salarios por region

print("STAR Schema – Salarios por region")
print(
    modelo_star_cmp.groupby(
        "region"
    )["total_usd"].sum().sort_values(ascending=False)
)

print("\nSnowflake Schema – Salarios por region")
print(
    modelo_snow_cmp.groupby(
        "region"
    )["total_usd"].sum().sort_values(ascending=False)
)

```

```
STAR Schema – Salarios por region
region
Zona Oriental      3751188.22
Zona Central       3430622.92
Zona Occidental    3002055.32
Name: total_usd, dtype: float64
```

```
Snowflake Schema – Salarios por region
region
Zona Central       3554912.31
Zona Occidental    3510119.59
Zona Oriental      3118834.56
Name: total_usd, dtype: float64
```

```
In [152... # kpi de promedio de salario

promedio_star = round(modelo_star_cmp["total_usd"].mean(), 2)

promedio_snow = round(modelo_snow_cmp["total_usd"].mean(), 2)

print(f"Promedio Salarial STAR:      ${promedio_star} USD")
print(f"Promedio Salarial Snowflake: ${promedio_snow} USD")
```

```
Promedio Salarial STAR:      $2036.77 USD
Promedio Salarial Snowflake: $2036.77 USD
```

```
In [153... # =====
# COMPARACIÓN FINAL DE RENDIMIENTO
# =====

print("Comparación de Rendimiento")
print(f"Tiempo STAR Schema:      {tiempo_star} segundos")
print(f"Tiempo Snowflake Schema: {tiempo_snow} segundos")
print(f"Número de JOINS STAR:      2")
print(f"Número de JOINS Snowflake: 5")

if tiempo_star < tiempo_snow:

    print("\nSTAR Schema fue mas rapido")

else:

    print("\nSnowflake Schema fue mas rapido")
```

```
Comparación de Rendimiento
Tiempo STAR Schema:      0.006742 segundos
Tiempo Snowflake Schema: 0.009951 segundos
Número de JOINS STAR:      2
Número de JOINS Snowflake: 5
```

```
STAR Schema fue mas rapido
```

Conclusión — Ejercicio 3 (STAR vs Snowflake)

Se construyeron dos modelos analíticos de Recursos Humanos con 5000 registros compartidos en la tabla fact, aplicados al contexto empresarial de El Salvador con salarios en

dólares (USD), lo que permite una comparación justa entre ambos esquemas.

El **STAR Schema** requirió únicamente 2 JOINS para ensamblar el modelo completo, ya que todas las dimensiones están desnormalizadas. Esto se traduce en mayor velocidad de ejecución y código más simple, a costa de cierta redundancia en los datos descriptivos.

El **Snowflake Schema** requirió 5 JOINS encadenados para incorporar la jerarquía completa (empleado → puesto, departamento, sede → región). Esto genera un modelo con menor redundancia y mayor integridad, pero con mayor complejidad y tiempo de procesamiento.

Ambos modelos arrojan los mismos KPIs de negocio, confirmando que la diferencia radica en la arquitectura y no en el resultado analítico.

Conclusión General

A lo largo de los tres ejercicios se construyeron modelos dimensionales completos para el área de Recursos Humanos, aplicados al contexto empresarial de El Salvador con salarios expresados en dólares (USD), partiendo de un STAR Schema simple hasta la comparación directa con el Snowflake Schema.

Ejercicio	Esquema	Registros	Dimensiones	JOINS
1 — STAR Schema	Desnormalizado	1 000	4	4
2 — Snowflake Schema	Normalizado	1 500	6	5
3 — Comparación	Ambos	5 000	STAR: 2 / Snow: 5	2 vs 5

Los conceptos clave aplicados fueron:

- Separación de tablas fact (métricas en USD) y tablas dimensión (contexto descriptivo)
- Uso de surrogate keys (`_key`) para independencia del sistema origen
- Normalización de dimensiones en el Snowflake Schema para reducir redundancia
- Generación de KPIs analíticos mediante `groupby` y agregaciones
- Medición de rendimiento con `time` para comparar ambos modelos

La elección entre STAR y Snowflake depende del contexto: el STAR Schema es ideal para dashboards rápidos y equipos pequeños, mientras que el Snowflake Schema se adapta mejor a organizaciones con jerarquías complejas y grandes volúmenes de datos donde la integridad y el almacenamiento son prioritarios.